

Kelompok Data Lab

- 1. Oktavian Dwi Putra
- 2. Muhammad Ilham
- 3. Maulid Uly Mada
- 4. Seto Bhanu Adyatma
- 5. Mega Pangastuti
- 6. Rasyidah Maulida P. A
- 7. M. Hasbi Ashshiddiqi
- 8. Raihan Damar

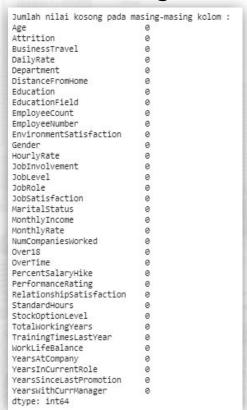




1. Data Cleansing



A. Handle missing values



Berdasarkan informasi di samping dapat disimpulkan bahwa **tidak terdapat missing value** pada semua kolom yang ada sehingga tidak diperlukan proses penghapusan *missing values*.



B. Handle data duplicated

```
# Menampilkan jumlah data duplicate
print("Jumlah data duplikat :")
df.duplicated().sum()

Jumlah data duplikat :
0
```

Berdasarkan informasi di samping dapat disimpulkan bahwa **tidak terdapat data yang terduplikasi** sehingga tidak diperlukan proses penghapusan *duplicated data*.



C. Handle outliers

```
# Menghapus outlier
from scipy import stats

print(f'Jumlah baris sebelum dilakukan penghapusan data outliers : {len(df)}')

filtered_entries = np.array([True] * len(df))

for col in ['MonthlyIncome', 'NumCompaniesMorked', 'TotalWorkingYears', 'TrainingTimesLastYear', 'YearsAtCompany', 'YearsInCurrentRole', 'YearsSinceLastPromotion', 'YearsWithCurrManager']:
    zscore = abs(stats.zscore(df[col])) # hitung absolute z-scorenya
    filtered_entries = (zscore < 3) & filtered_entries # keep yang kurang dari 3

df = df[filtered_entries] # filter, cuma ambil yang z-scorenya dibawah 3

print(f'Jumlah baris setelah dilakukan penghapusan data outliers : {len(df)}')

Jumlah baris sebelum dilakukan penghapusan data outliers : 1470

Jumlah baris setelah dilakukan penghapusan data outliers : 1387
```

- Dilakukan proses penghapusan data outliers pada kolom MonthlyIncome,
 NumCompaniesWorked, TotalWorkingYears, TrainingTimesLastYear, YearsAtCompany,
 YearsInCurrentRole, YearsSinceLastPromotion, dan YearsWithCurrManager.
- Berdasarkan informasi di atas, didapatkan bahwa sebelum dilakukan penghapusan data *outliers* terdapat **1470** baris data dan setelah dilakukan penghapusan data *outliers* terdapat **1387** baris data.



D. Feature encoding

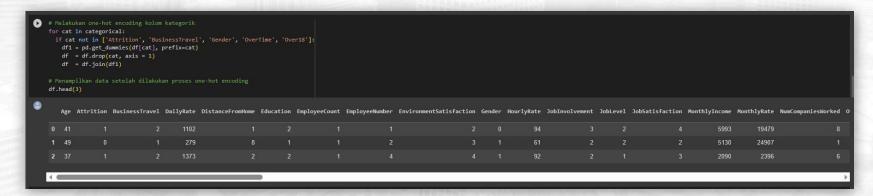
Melakukan feature encoding pada kolom **Attrition, BusinessTravel, Gender,** dan **Overtime** menjadi **numerical** dengan menggunakan metode label encoding sehingga model lebih mudah dipahami.

df['Business df['Gender'] df['OverTime # Menampilka df.head(3)	sTravel'] = La] = LabelEncod e'] = LabelEnc an data setela	belEncoder() er().fit_tra oder().fit_t h dilakukan	transform .fit_tran nsform(df ransform(proses la	df['OverTime'])	ation [EducationField	EmployeeCount Em	oloyeeNumber Environm	entSatisfaction	Gender	HourlyRate	JobInvolvement	JobLevel	JobRole	JobSatisfaction	Marit
				Sales		Life Sciences	1				94			Sales Executive		
				Research & Development		Life Sciences								Research Scientist		
			1373	Research &		Other					92			Laboratory Technician		



D. Feature encoding - One hot encoding

Melakukan feature encoding pada kolom yang memiliki lebih dari dua tingkatan/kelas yakni kolom Attrition, BusinessTravel, Gender, Overtime, dan Over18 dengan menggunakan metode One hot encoding sehingga memunculkan seluruh tingkatan/kelas menjadi feature yang baru.





D. Feature encoding

Setelah dilakukan proses feature encoding terdapat peningkatan jumlah kolom menjadi 51 kolom, yang sebelumnya berjumlah 34 kolom. Peningkatan jumlah kolom ini disebabkan oleh penggunaan metode One Hot Encoding yang nantinya kelas/tingkatan pada kolom tersebut menjadi kolom baru seperti kolom MaritalStatus_Divorced, MaritalStatus_Married, MaritalStatus_Single, dll.

	ss 'pandas.core.frame.DataFrame'> 4Index: 1387 entries, 0 to 1469		
Data	columns (total 52 columns):		
	Column	Non-Null Count	Dtype
8		1387 non-null	int64
1	Age Attrition	1387 non-null	int64
2	BusinessTravel	1387 non-null	int64
3	DailyRate	1387 non-null	int64
4	DistanceFromHome	1387 non-null	int64
5	Education	1387 non-null	int64
6	EmployeeCount	1387 non-null	int64
7	EmployeeNumber	1387 non-null	int64
8	EnvironmentSatisfaction	1387 non-null	int64
å	Gender	1387 non-null	int64
18	HourlyRate	1387 non-null	int64
11	JobInvolvement	1387 non-null	int64
12	JobLevel	1387 non-null	int64
13	JobSatisfaction	1387 non-null	int64
14	MonthlyIncome	1387 non-null	int64
15	MonthlyRate	1387 non-null	int64
16	NumCompaniesWorked	1387 non-null	int64
17	Over18	1387 non-null	object
18	OverTime	1387 non-null	int64
19	PercentSalaryHike	1387 non-null	int64
20	PerformanceRating	1387 non-null	int64
21	RelationshipSatisfaction	1387 non-null	int64
22	StandardHours	1387 non-null	int64
23	StockOptionLevel	1387 non-null	int64
24	TotalWorkingYears	1387 non-null	int64
25	TrainingTimesLastYear	1387 non-null	int64
26	WorkLifeBalance	1387 non-null	int64
27	YearsAtCompany	1387 non-null	int64
28	YearsInCurrentRole	1387 non-null	int64
29	YearsSinceLastPromotion	1387 non-null	int64
30	YearsWithCurrManager	1387 non-null	int64
31	Department Human Resources	1387 non-null	uint8
32	Department Research & Development	1387 non-null	uint8
33	Department Sales	1387 non-null	uint8
34	EducationField Human Resources	1387 non-null	uint8
35	EducationField Life Sciences	1387 non-null	uint8
36	EducationField Marketing	1387 non-null	uint8
37	EducationField Medical	1387 non-null	uint8
38	EducationField Other	1387 non-null	uint8
39	EducationField_Technical Degree	1387 non-null	uint8
40	JobRole Healthcare Representative	1387 non-null	uint8
41	JobRole Human Resources	1387 non-null	uint8
42	JobRole Laboratory Technician	1387 non-null	uint8
43	JobRole Manager	1387 non-null	uint8
44	JobRole Manufacturing Director	1387 non-null	uint8
45	JobRole_Research Director	1387 non-null	uint8
46	JobRole Research Scientist	1387 non-null	uint8
47	JobRole Sales Executive	1387 non-null	uint8
48	JobRole Sales Representative	1387 non-null	uint8
49	MaritalStatus Divorced	1387 non-null	uint8
50	MaritalStatus Married	1387 non-null	uint8
51	MaritalStatus_Single	1387 non-null	uint8
dtyp	es: int64(30), object(1), uint8(21)		



2. Feature Engineering



A. Feature selection

```
# Melakukan penghapusan kolom dengan nilai unik 1 dan nilai unik yang sama dengan jumlah baris
df_new = df.drop(columns = ['EmployeeNumber', 'EmployeeCount', 'StandardHours', 'Over18'])
df new.info()
<class 'pandas.core.frame.DataFrame'>
Int64Index: 1387 entries, 0 to 1469
Data columns (total 48 columns):
                                       Non-Null Count Dtype
                                       1387 non-null
1 Attrition
    BusinessTravel
                                       1387 non-null
3 DailyRate
                                       1387 non-null
    DistanceFromHome
5 Education
                                       1387 non-null
    EnvironmentSatisfaction
                                       1387 non-null
    HourlyRate
                                       1387 non-null
    JobInvolvement
                                       1387 non-null
 10 JobLevel
11 JobSatisfaction
                                       1387 non-null
 12 MonthlyIncome
                                       1387 non-null
 13 MonthlyRate
 14 NumCompaniesWorked
                                       1387 non-null
15 OverTime
                                       1387 non-null
 16 PercentSalaryHike
                                       1387 non-null
17 PerformanceRating
                                       1387 non-null
 18 RelationshipSatisfaction
                                       1387 non-null
 19 StockOptionLevel
                                       1387 non-null
 20 TotalWorkingYears
                                       1387 non-null
 21 TrainingTimesLastYear
                                       1387 non-null
                                       1387 non-null
23 YearsAtCompany
                                       1387 non-null
24 YearsInCurrentRole
25 YearsSinceLastPromotion
                                       1387 non-null
 26 VearsWithCurrManager
                                       1387 non-null
27 Department Human Resources
                                       1387 non-null
 28 Department_Research & Development 1387 non-null
29 Department Sales
                                      1387 non-null
 30 EducationField_Human Resources
31 EducationField_Life Sciences
                                       1387 non-null
32 EducationField Marketing
                                       1387 non-null
 33 EducationField_Medical
34 EducationField Other
                                       1387 non-null
 35 EducationField_Technical Degree
                                      1387 non-null
 36 JobRole Healthcare Representative 1387 non-null
37 JobRole Human Resources
                                       1387 non-null
 38 JobRole Laboratory Technician
                                      1387 non-null
 39 JobRole Manager
 40 JobRole_Manufacturing Director
                                      1387 non-null
41 JobRole Research Director
 42 JobRole_Research Scientist
43 JobRole_Sales Executive
                                       1387 non-null
 44 JobRole Sales Representative
                                      1387 non-null
                                                      uint8
 45 MaritalStatus Divorced
                                       1387 non-null
46 MaritalStatus_Married
                                      1387 non-null
47 MaritalStatus Single
                                       1387 non-null
dtypes: int64(27), uint8(21)
memory usage: 364.1 KB
```

Setelah dilakukan proses feature encoding, selanjutnya dilakukan penghapusan kolom yang memiliki nilai unik sebanyak 1 dan kolom yang memiliki nilai unik sebanyak jumlah baris. Kemudian terjadi penurunan jumlah kolom menjadi 48 kolom.



A. Feature selection

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 1387 entries, 0 to 1469
Data columns (total 32 columns):
                                      Non-Null Count Dtype
                                      1387 non-null
                                                     int64
    Attrition
                                      1387 non-null
                                                     int64
2 DailyRate
                                      1387 non-null
                                                     int64
                                      1387 non-null
                                                     int64
   EnvironmentSatisfaction
                                      1387 non-null
                                                     int64
5 Johnnyolvement
                                      1387 non-null
                                                     int64
   JobLevel
                                      1387 non-null
                                                     int64
7 JobSatisfaction
                                      1387 non-null
                                                     int64
   MonthlyIncome
                                                     int64
                                      1387 non-null
9 NumCompaniesWorked
                                      1387 non-null
                                                     int64
10 OverTime
                                      1387 non-null
                                                     int64
11 RelationshipSatisfaction
                                                     int64
                                      1387 non-null
12 StockOptionLevel
                                      1387 non-null
                                                     int64
13 TotalWorkingYears
                                      1387 non-null
                                                     int64
14 TrainingTimesLastYear
                                      1387 non-null
                                                     int64
15 WorkLifeBalance
                                      1387 non-null
                                                     int64
16 YearsAtCompany
                                      1387 non-null
                                                     int64
17 YearsInCurrentRole
                                      1387 non-null
                                                     int64
18 YearsWithCurrManager
                                      1387 non-null
                                                     int64
19 Department Research & Development 1387 non-null
                                                     uint8
20 Department Sales
                                      1387 non-null
                                                     uint8
21 EducationField Marketing
                                      1387 non-null
                                                     uint8
22 EducationField Technical Degree 1387 non-null
                                                     uint8
23 JobRole Healthcare Representative 1387 non-null
                                                     uint8
24 JobRole Laboratory Technician
                                      1387 non-null
                                                     uint8
25 JobRole Manager
                                      1387 non-null
                                                     uint8
26 JobRole_Manufacturing Director
                                      1387 non-null
                                                     uint8
27 JobRole Research Director
                                      1387 non-null
                                                     uint8
28 JobRole Sales Representative
                                      1387 non-null
                                                     uint8
29 MaritalStatus Divorced
                                      1387 non-null
                                                     uint8
30 MaritalStatus Married
                                      1387 non-null
                                                     uint8
31 MaritalStatus Single
                                      1387 non-null
                                                     uint8
dtvpes: int64(19), uint8(13)
memory usage: 266.6 KB
```

```
# Menghilangkan kolom yang memiliki nilai korelasi rendah terhadap target (korelasi dibawah 0.05)
# Kolom target yang akan digunakan sebagai referensi
target_column = 'Attrition'

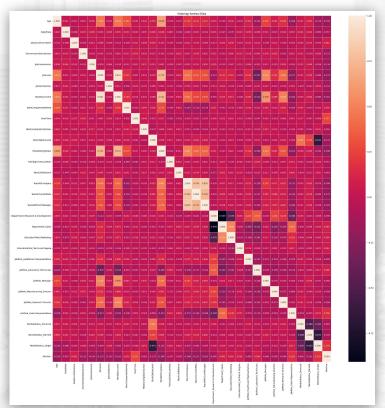
# Hitung korelasi terhadap kolom target
correlation_with_target = df_new.corr()[target_column].drop(target_column)

# Hilangkan kolom-kolom dengan korelasi di bawah 0.05 terhadap kolom target
threshold = 0.05
columns_to_drop = correlation_with_target[abs(correlation_with_target) < threshold].index
data filtered = df_new.drop(columns=columns_to_drop)</pre>
```

Selanjutnya dilakukan penghapusan kolom yang memiliki nilai korelasi yang rendah terhadap target (korelasi dibawah 0.05). Kemudian terjadi penurunan jumlah kolom menjadi 32 kolom.



A. Feature selection



Dilakukan proses analisa menggunakan heatmap untuk melihat korelasi antar feature. Kemudian karena terdapat multicollinearity (korelasi yang memiliki nilai diatas 0.7) antara kolom "JobLevel", "MonthlyIncome", dan "TotalWorkingYears" serta kolom "YearsAtCompany", "YearsInCurrentRole", dan "YearsWithCurrManager" sehingga dipilih salah satu kolom saja.



A. Feature selection

```
data_filtered = data_filtered.drop(['JobLevel', 'MonthlyIncome', 'YearsAtCompany', 'YearsWithCurrManager'], axis = 1)
data_filtered.info()
<class 'pandas.core.frame.DataFrame'>
Int64Index: 1387 entries, 0 to 1469
Data columns (total 28 columns):
    Column
                                      Non-Null Count Dtype
                                      1387 non-null
    DailyRate
                                      1387 non-null
2 DistanceFromHome
                                      1387 non-null
                                                      int64
    EnvironmentSatisfaction
                                      1387 non-null
    JobInvolvement
                                                     int64
                                      1387 non-null
   JobSatisfaction
                                      1387 non-null
                                                     int64
    NumCompaniesWorked
                                      1387 non-null
                                                     int64
7 OverTime
                                      1387 non-null
                                                     int64
    RelationshipSatisfaction
                                      1387 non-null
9 StockOptionLevel
                                      1387 non-null
                                                      int64
10 TotalWorkingYears
                                      1387 non-null
11 TrainingTimesLastYear
                                      1387 non-null
                                                     int64
12 WorkLifeBalance
                                      1387 non-null
                                                     int64
13 YearsInCurrentRole
                                      1387 non-null
                                                      int64
14 Department Research & Development 1387 non-null
                                                     uint8
15 Department Sales
                                      1387 non-null
16 EducationField Marketing
                                      1387 non-null
                                                     uint8
17 EducationField Technical Degree 1387 non-null
                                                      uint8
18 JobRole_Healthcare Representative 1387 non-null
                                                      uint8
19 JobRole Laboratory Technician
                                      1387 non-null
                                                      uint8
20 JobRole Manager
                                      1387 non-null
                                                      uint8
21 JobRole_Manufacturing Director
                                      1387 non-null
                                                     uint8
22 JobRole_Research Director
                                      1387 non-null
                                                      uint8
23 JobRole Sales Representative
                                      1387 non-null
                                                     uint8
24 MaritalStatus Divorced
                                                      uint8
                                      1387 non-null
25 MaritalStatus_Married
                                                      uints
                                      1387 non-null
26 MaritalStatus_Single
                                      1387 non-null
                                                     uint8
27 Attrition
                                      1387 non-null
dtypes: int64(15), uint8(13)
memory usage: 223.3 KB
```

multicollinearity, dilakukan penghapusan kolom yang memiliki korelasi lebih rendah terhadap target yaitu "JobLevel" dan "MonthlyIncome" serta kolom "YearsAtCompany" dan "YearsWithCurrManager".

Kemudian terjadi penurunan jumlah kolom menjadi 28 kolom.



B. Feature extraction

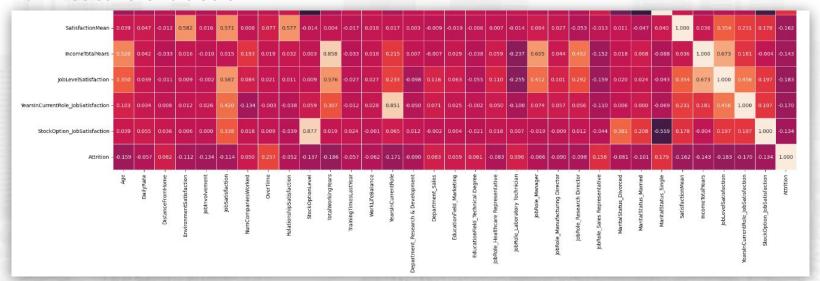
```
# Membuat fitur baru
data_filtered['SatisfactionMean'] = ( df_new['EnvironmentSatisfaction'] + df_new['JobSatisfaction'] + df_new['RelationshipSatisfaction'] ) / 3
data_filtered['IncomeTotalYears'] = df_new['MonthlyIncome']*df_new['TotalWorkingYears']
data_filtered['JobLevelSatisfaction'] = df_new['JobLevel'] * df_new['JobSatisfaction']
data_filtered['YearsInCurrentRole_JobSatisfaction'] = df_new['YearsInCurrentRole'] * df_new['JobSatisfaction']
data_filtered['StockOption_JobSatisfaction'] = df_new['StockOptionLevel'] * df_new['JobSatisfaction']
```

Selanjutnya dilakukan pembuatan feature baru dengan rincian sebagai berikut :

- 1. "SatisfactionMean" yaitu hasil rataan dari kolom satisfaction.
- 2. "IncomeTotalYears" yaitu hasil kali antara kolom "MonthlyIncome" dengan "TotalWorkingYears".
- 3. "JobLevelSatisfaction" yaitu hasil kali antara kolom "JobLevel" dengan "JobSatisfaction".
- 4. **"YearsInCurrentRole_JobSatisfaction"** yaitu hasil kali antara kolom **"YearsInCurrentRole"** dengan **"JobSatisfaction"**.
- 5. "StockOption_JobSatisfaction" yaitu hasil kali antara "StockOptionLevel" dengan "JobSatisfaction".



B. Feature extraction



Setelah proses pembuatan *feature* baru, dilakukan pengecekan korelasi feature baru terhadap target dengan menggunakan heatmap. Hasil korelasi yang didapatkan dari feature baru berkisar antara 0.13 sampai 0.18. Kemudin, terjadi peningkatan jumlah kolom menjadi 33 kolom.



B. Feature extraction

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 1387 entries, 0 to 1469
Data columns (total 27 columns):
    Column
                                       Non-Null Count Dtype
                                       1387 non-null
                                                       int64
    DailyRate
                                       1387 non-null
                                                       int64
    DistanceFromHome
                                       1387 non-null
                                                       int64
    lobInvolvement
                                                       int64
                                       1387 non-null
    NumCompaniesWorked
                                       1387 non-null
                                                       int64
    OverTime
                                       1387 non-null
                                                       int64
    StockOptionLevel
                                       1387 non-null
                                                       int64
    TotalWorkingYears
                                       1387 non-null
                                                       int64
    TrainingTimesLastYear
                                       1387 non-null
                                                       int64
    WorkLifeBalance
                                       1387 non-null
                                                       int64
10 YearsInCurrentRole
                                       1387 non-null
                                                       int64
11 Department Research & Development 1387 non-null
                                                       uint8
12 Department Sales
                                       1387 non-null
                                                       uint8
13 EducationField Marketing
                                       1387 non-null
                                                       uint8
14 EducationField Technical Degree
                                       1387 non-null
                                                       uint8
15 JobRole Healthcare Representative 1387 non-null
                                                       uint8
16 JobRole Laboratory Technician
                                                       uint8
                                       1387 non-null
17 JobRole Manager
                                       1387 non-null
                                                       uint8
18 JobRole Manufacturing Director
                                       1387 non-null
                                                       uints
19 JobRole Research Director
                                       1387 non-null
                                                       uint8
20 JobRole Sales Representative
                                       1387 non-null
                                                       uint8
21 MaritalStatus Divorced
                                       1387 non-null
                                                       uint8
22 MaritalStatus Married
                                       1387 non-null
                                                       uint8
23 MaritalStatus Single
                                       1387 non-null
                                                       uint8
24 SatisfactionMean
                                       1387 non-null
                                                       float64
25 JobLevelSatisfaction
                                       1387 non-null
                                                       int64
26 Attrition
                                       1387 non-null
                                                       int64
dtypes: float64(1), int64(13), uint8(13)
memory usage: 212.4 KB
```

Selanjutnya dilakukan penghapusan kolom yang dipergunakan untuk membuat feature baru dimana feature tersebut memiliki korelasi yang lebih rendah jika dibandingkan dengan korelasi feature baru terhadap target.

Kemudian, juga dilakukan penghapusan terhadap feature baru yang memiliki korelasi yang lebih rendah dibandingkan dengan korelasi kolom yang digunakan untuk membuat feature baru tersebut terhadap target. Selanjutnya terjadi penurunan jumlah kolom menjadi 27 kolom



C. Feature transformation

	Age	DailyRate	DistanceFromHome	JobInvolvement	NumCompaniesWorked	OverTime	StockOptionLevel	TotalWorkingYears	TrainingTimesLastYear	WorkLifeBalance	YearsInCurrentRole
count	1.387000e+03	1.387000e+03	1.387000e+03	1.387000e+03	1.387000e+03	1387.000000	1.387000e+03	1.387000e+03	1.387000e+03	1.387000e+03	1.387000e+03
mean	-3.201797e-16	-3.073725e-17	-7. <mark>684312e-18</mark>	-1.511248e-16	1.018171e-16	0.284787	4.098300e-17	-8.452743e-17	1.793006e-17	1.562477e-16	5.122875e-18
std	1.000361e+00	1.000361e+00	1.000361e+00	1.000361e+00	1.000361e+00	0.451476	1.000361e+00	1.000361e+00	1.000361e+00	1.000361e+00	1.000361e+00
min	-2.066430e+00	-1.746955e+00	-1.011249e+00	-2.444483e+00	-1.072199e+00	0.000000	-9.294273e-01	-1.538219e+00	-2.171420e+00	-2.501172e+00	-1.192419e+00
25%	-7.082852e-01	-8.400474e-01	-8.875735e-01	-1.034126e+00	-6.724300e-01	0.000000	-9.294273e-01	-6.423508e-01	-6.225595e-01	-1.082307e+00	-5.757580e-01
50%	-1.423914e-01	2.347108e-03	-2.691967e-01	3.762308e-01	-2.726613e-01	0.000000	2.382499e-01	-1.944169e-01	1.518710e-01	3.365585e-01	-2.674274e-01
75%	6.498599e-01	8.782389e-01	5.965307e-01	3.762308e-01	5.268762e-01	1.000000	2.382499e-01	4.028283e-01	1.518710e-01	3.365585e-01	9.658952e-01
max	2.687077e+00	1.716911e+00	2.451661e+00	1.786588e+00	2.525720e+00	1.000000	2.573604e+00	3.538366e+00	2.475162e+00	1.755424e+00	3.432540e+00

Dilakukan transformasi pada setiap *feature* dengan menggunakan **metode standarisasi**. Setelah dilakukan transformasi seluruh *feature* memiliki **simpangan baku = 1** dan **rata-rata mendekati 0**.



D. Class imbalance

```
# Membagi data menjadi target dan fitur
x = data baru[[col for col in data_baru.columns if col not in ['Attrition']]]
y = data_baru['Attrition'].values
print("Jumlah perbandingan antara kelas attrition dan tidak attrition sebelum class imbalance :")
print(pd.Series(y).value_counts())
Jumlah perbandingan antara kelas attrition dan tidak attrition sebelum class imbalance :
    1158
     229
dtvpe: int64
# Melakukan handling class imbalance
from imblearn import over sampling
x over, y over = over sampling.SMOTE(sampling strategy = 1).fit resample(x, y)
print("Jumlah perbandingan antara kelas attrition dan tidak attrition setelah class imbalance :")
print(pd.Series(y over).value counts())
Jumlah perbandingan antara kelas attrition dan tidak attrition setelah class imbalance :
     1158
     1158
dtype: int64
```

Dilakukan pembagian data menjadi target (y) dan fitur (x) dalam suatu pemodelan machine learning. Pada proses ini, diasumsikan kolom 'Attrition' merupakan variabel target yang ingin diprediksi, dan kolom-kolom lainnya merupakan fitur-fitur yang digunakan untuk melakukan prediksi. Kemudian, didapatkan bahwa perbandingan antara kelas attrition dan tidak attrition pada kolom **AttritionNum** mendekati **1:5**, sehingga perlu dilakukan proses **handling class imbalance**.

Dilakukan proses handling class imbalance menggunakan metode SMOTE (Synthetic Minority Over-sampling Technique). Kelas 1 (attrition) memiliki jumlah sampel sebanyak 1158 dan kelas 0 (tidak attrition) juga memiliki jumlah sampel sebanyak 1158. Sehingga, perbandingan jumlah sampel antara kelas 'attrition' dan 'tidak attrition' menjadi 1:1, dengan kata lain setiap kelas memiliki jumlah sampel yang sama. Hal ini menunjukkan bahwa metode SMOTE telah berhasil menambahkan sampel sintetis pada kelas minoritas sehingga mengatasi class imbalance pada data.



D. Class imbalance

```
# Menggabungkan kembali data setelah dilakukan handling class imbalance
data_final = x_over
data final['Attrition'] = y over
data_final.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2316 entries, 0 to 2315
Data columns (total 27 columns):
                                      Non-Null Count Dtvpe
    Column
    Age
                                      2316 non-null
                                                      float64
    DailyRate
                                      2316 non-null
                                                      float64
    DistanceFromHome
                                      2316 non-null
                                                      float64
    JobInvolvement
                                      2316 non-null float64
    NumCompaniesWorked
                                      2316 non-null
                                                     float64
   OverTime
                                      2316 non-null
                                                     int64
    StockOptionLevel
                                      2316 non-null
                                                      float64
    TotalWorkingYears
                                      2316 non-null
                                                     float64
   TrainingTimesLastYear
                                                     float64
                                      2316 non-null
    WorkLifeBalance
                                      2316 non-null
                                                      float64
10 YearsInCurrentRole
                                                      float64
                                      2316 non-null
11 Department_Research & Development 2316 non-null
                                                     uint8
12 Department Sales
                                      2316 non-null
                                                      uints
13 EducationField Marketing
                                      2316 non-null
                                                      uint8
14 EducationField_Technical Degree
                                      2316 non-null
                                                      uint8
15 JobRole Healthcare Representative
                                      2316 non-null
                                                      uint8
16 JobRole_Laboratory Technician
                                      2316 non-null
                                                      uint8
17 JobRole Manager
                                      2316 non-null
                                                      uints
18 JobRole_Manufacturing Director
                                      2316 non-null
                                                      uint8
19 JobRole Research Director
                                      2316 non-null
                                                      uint8
20 JobRole Sales Representative
                                      2316 non-null
                                                      uint8
21 MaritalStatus Divorced
                                      2316 non-null
                                                     uints
22 MaritalStatus Married
                                      2316 non-null
                                                      uints
23 MaritalStatus_Single
                                      2316 non-null
                                                      uint8
24 SatisfactionMean
                                      2316 non-null
                                                     float64
25 JobLevelSatisfaction
                                      2316 non-null
                                                      float64
26 Attrition
                                                     int64
                                      2316 non-null
dtypes: float64(12), int64(2), uint8(13)
memory usage: 282.8 KB
```

Dilakukan penggabungan kembali telah feature yang dilakukan handling class imbalance metode menggunakan SMOTE pada data_final. Kemudian, data siap digunakan untuk proses pemodelan atau analisis selanjutnya.



E. Feature tambahan

https://github.com/megapangastuti/Rakamin-Project.git

- WorkingHours (Integer): Jumlah jam kerja karyawan dalam satu bulan.
 Berdasarkan UU Ketenagakerjaan jumlah jam kerja karyawan dalam 1 bulan rata-rata adalah 173 jam.
 Fitur ini bisa digunakan untuk menganalisa durasi maksimal seorang karyawan bekerja melebihi jam kerja reguler yang akan membuat karyawan cenderung untuk bertahan di perusahaan.
- Absence (Integer): Jumlah hari karyawan tidak masuk kerja dalam 1 bulan.
 Karyawan yang ingin keluar dari perusahaan cenderung untuk lebih banyak absen dibandingkan yang tidak.
- ManagerSatisfaction (Integer): Tingkat kepuasan karyawan terhadap manager.
 Semakin tinggi tingkat kepuasan seorang karyawan terhadap manager, maka semakin rendah juga kemungkinan mereka untuk keluar dari perusahaan.
- EmployeeEngagement (Integer): Tingkat keterlibatan karyawan dengan event yang diadakan oleh perusahaan dan hubungan dengan karyawan lainnya.

 Semakin tinggi tingkat keterlibatan seorang karyawan, maka semakin rendah juga kemungkinan mereka untuk keluar dari perusahaan.



3. Git



3. Git (15 Poin)

File homework stage 2 dapat di akses pada link berikut :

